Daniel Vegara 17/12/2023

Transparencia en algoritmos de recomendación

Facebook se fundó en 2004, y en 2021 alcanzó un valor en bolsa de $1 billón. Su modelo de negocio, así como el de Google, Instagram y TikTok, se basa en gran parte en sistemas de recomendación. Estos algoritmos se utilizan para elegir el contenido y anuncios que ve cada usuario. Presentan peligros y sesgos cuyo estudio se ve mermado por la falta de transparencia en el sector. Este texto trata los sistemas de recomendación como ejemplo de la situación actual en cuanto a transparencia algorítmica de las grandes tecnológicas.

Google, Twitter, Amazon y Meta, con una capitalización bursátil combinada de $4.12 billones, basan sus modelos de negocio en sistemas de recomendación (SR). Estos algoritmos recopilan información sobre el usuario para encontrar contenido que incrementará el tiempo de uso (o diferentes métricas como ventas, “likes” o comentarios), y, por lo tanto, el número de anuncios visto. A medida que incrementa el tiempo en la plataforma, el aumento de datos produce una mejora en el SR, que se aplica a su vez para mostrar anuncios más precisos. El tiempo elevado de uso no es un efecto secundario: suele ser la meta misma de estos algoritmos.

Los SR aprenden sobre cada usuario de la plataforma observando su comportamiento en la misma. A través de varios métodos de IA, se priorizan elementos del contenido con el que el usuario interactúa para generar el contenido subsiguiente. La preocupación básica es que, *dado que el SR elige el orden de los elementos en el “feed” de cada usuario, influye en su propio aprendizaje subsiguiente*.

El hecho de que los SR aprendan de y ejerzan influencia sobre el comportamiento de los usuarios significa que pueden llevar a los usuarios hacia dominios de contenido progresivamente más nicho, en direcciones que el usuario por sí mismo no habría tomado. Esta preocupación se puede demostrar fácilmente en estudios teóricos de SR: un análisis de Google DeepMind (4) muestra el efecto claramente (e incluye una descripción técnica de estos algoritmos).

Parte del problema es la falta de profesionales especializados en algoritmos de este tipo. Según Frances Haugen, una ex gerente de producto de Facebook, “solo hay entre 300 y 400 expertos en algoritmos en todo el mundo” (3). La conversación no está abierta al público, lo cual reduce las capacidades regulatorias.

La opacidad de estos métodos ha generado controversia, especialmente tras los casos de Facebook en Myanmar (1) y Cambridge Analytica. La influencia que tienen estos algoritmos sobre la población es innegable, y su potencial negativo enorme. El efecto es preocupante en parte porque el número de personas que consumen sus noticias a través de redes sociales sigue creciendo (2). Los SR ejercen de editorial personalizada para cada usuario, con una influencia enorme sobre las dinámicas de opinión pública y política.

Informes de transparencia

Los informes de transparencia han ido aumentando en el sector tecnológico. Estos documentos abordan principalmente temas de prácticas de moderación de contenido y solicitudes de datos por parte del gobierno. Raramente incluyen información sobre los SR de las plataformas. Por ejemplo, los informes de transparencia de Facebook (5) incluyen secciones relacionadas con restricciones, propiedad intelectual, contenido popular… nada sobre cómo funcionan los algoritmos que deciden el contenido de cada usuario. TikTok (6) y Google (12) siguen modelos similares (Tabla 1).

Una excepción es X (Twitter), que tras ser adquirido por Elon Musk ha hecho públicas varias partes del código utilizado para generar el contenido de sus usuarios. Musk ha dicho que, como parte de su compromiso con la transparencia de la plataforma, en un futuro todo el código de Twitter será público (7). Según una publicación en el blog de Twitter, el proceso se divide en tres etapas (Fig 1). Primero, Twitter reúne los mejores tweets de diferentes SR, los clasifica usando un modelo de IA, y finalmente filtra los tweets que ya has visto antes o de personas que has bloqueado. La publicación explica en más detalle cada paso (13). Por ejemplo, señala que de los 1500 tweets generado para cada “feed” aproximadamente el 50% vienen de tweets de personas que sigues (“in-network”) y el 50% de cuentas fuera de tu red (“out-of-network”). Indican que la clasificación tiene como objetivo optimizar “interacciones positivas” (“me gusta”, “retweet”, respuestas). Aún así, la falta de conocimiento sobre los pesos de sus modelos deja sin responder preguntas sobre qué tipo de contenido se propaga.

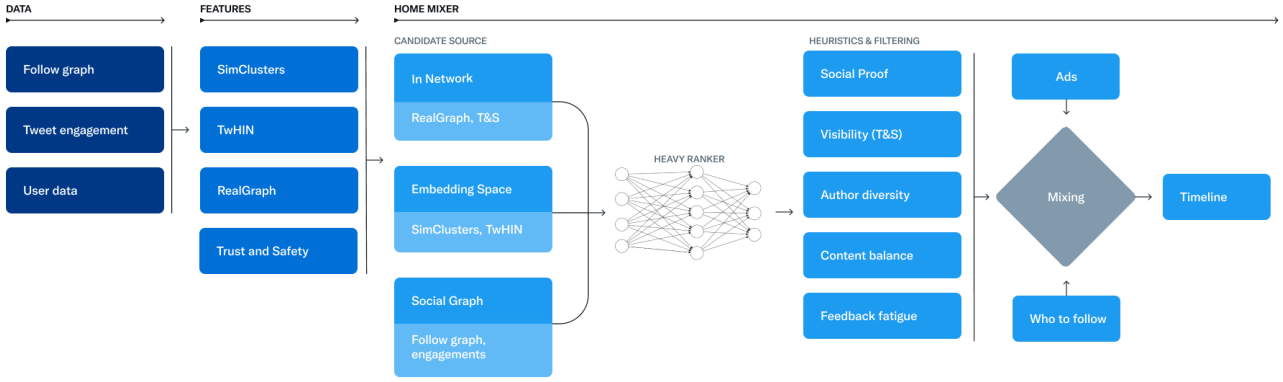

Fig 1: componentes principales en la construcción del “feed” de Twitter

Ley de Servicios Digitales

Ursula von der Leyen propuso una "nueva Ley de Servicios Digitales", en su candidatura de 2019 a la presidencia de la Comisión Europea. El propósito expreso (8) es actualizar el marco legal de la Unión Europea para el contenido ilegal en las grandes plataformas. Incluye una nueva opción a SR sin perfilar, pero aunque pide transparencia adicional en la publicidad, no implica la publicación de informes sobre los algoritmos utilizados (Tabla 2). Aunque incrementa la transparencia, la cuestión clave de cómo funcionan estos algoritmos y cómo afectan al usuario sigue sin tratar.

Cartas de Derechos Digitales

La Carta de Derechos Digitales española (9) enfatiza la importancia de adaptar y proteger los derechos fundamentales en el entorno digital. No busca crear nuevos derechos sino perfilar los existentes, describiendo derechos instrumentales o auxiliares. Reconoce que es vital adaptar los derechos e interpretación al cambio constante del mundo digital. Abarca aspectos como la libertad de expresión, la protección de datos, la ciberseguridad, los derechos en el ámbito laboral, la igualdad de género en los entornos digitales, y el acceso a Internet. Habla de medidas específicas para reducir sesgos algorítmicos, pero no prioriza nuevos temas de transparencia algorítmica.

Métodos externos de evaluación

En el ambiente académico se han encontrado varias formas de estudiar los efectos de los SR sin acceso especial a los procesos y datos de estas empresas. Una revisión mas extensa con más ejemplos se puede encontrar en (10).

- Estudios de población: utilizan datos de grupos grandes de personas para comparar actitudes con uso de redes sociales. Por ejemplo, en (11) se estudia la polarización política en EEUU y su relación (o falta de) con las redes. Estos estudios son útiles para estudiar las diferencias en los efectos de las redes sociales en diferentes lugares, a lo largo del tiempo y entre diferentes grupos. Sin embargo, a menudo existen variables que podrían explicar diferencias pero que se ven excluidas.
- Browser logging studies (estudios de registro en navegadores): observan el comportamiento de voluntarios en redes sociales durante un periodo de tiempo. Pueden enfocarse de forma más detallada en los SR ya que observan cómo interactúa el usuario con las recomendaciones. Un estudio reciente de registro en navegadores de YouTube (12) encontró que el algoritmo de recomendación de YouTube canalizaba a los usuarios de EEUU hacia "cámaras de eco”, aislando a liberales y conservadores. Estos estudios revelan una imagen más detallada de las interacciones de los usuarios con el SR, pero pueden sufrir problemas sistemáticos con el muestreo de voluntarios. Puede ser que los usuarios más susceptibles a la radicalización también sean menos propensos a compartir sus datos de navegación con investigadores experimentales.
- Estudios de usuario robot**:** simulan usuarios individuales con tendencia a seguir enlaces recomendados. Si los usuarios siguen los enlaces recomendados en una plataforma, ¿dónde acaban? En general, los seguidores de enlaces robot siguen reglas muy simples. No están destinados a ser simulaciones precisas de lo que la gente realmente hace: muestran lo que sucedería si un usuario siguiera los enlaces que se le recomiendan. Estos usuarios robot típicamente tienen historiales de navegación muy escasos, por lo que lo que el SR sabe sobre ellos es muy limitado. Es difícil sacar conclusiones de estos estudios sobre los efectos de los SR en personas reales.

Métodos internos de evaluación

Una forma popular de evaluación para las empresas son las pruebas A-B. En una prueba A-B, se identifica un conjunto concreto de usuarios, y estos se dividen aleatoriamente en varios grupos. A cada grupo se le ofrece una versión diferente del SR de la plataforma. Hay muchos aspectos del SR que se pueden variar, por lo que hay un amplio espacio de posibles "versiones" para probar. Al final de un período de prueba, durante el cual los usuarios interactúan con la versión asignada del SR, se toman diferentes medidas del comportamiento de los usuarios y se calculan promedios de estas medidas en cada grupo. Si hay diferencia significativas entre grupos en cualquier métrica, se pueden atribuir de manera confiable a la versión del SR a la que fueron expuestos.

Siguientes pasos

El artículo *Transparency Mechanisms for Social Media Recommender Algorithms: From Proposals to Action* (14) ofrece detalles sobre métodos de evaluación externos e internos así como una visión más completa de la transparencia algorítmica en la industria. Propone varios enfoques para abordar el tema, entre ellos:

- Reunir apoyo gubernamental para iniciativas de transparencia
- Involucrar a ingenieros de software y data scientists en discusiones de transparencia
- Enfocar la discusión en proyectos piloto
- Crear divulgación científica en torno a los efectos de estos algoritmos

	Facebook	Google	TikTok
Propiedad Intelectual	x		x
Peticiones de datos de gobiernos	x	x	x
Restricciones	x	x	x
Informes Regulatorios	x	x	x
Peticiones de datos privadas		x	x
Anuncios políticos		x	

Tabla 1: resumen del contenido de los informes de transparencia.

Nueva obligación	Servicios de intermediación	Servicios de alojamiento	Plataformas en línea	Plataformas de muy gran tamaño
Informes de transparencia	•	•	•	•
Nuevos requisitos sobre las condiciones de servicio	•	•	•	•
Colaboración con las autoridades nacionales	•	•	•	•
Puntos de contacto y representante legal	•	•	•	•
Mecanismo de notificación de contenido ilegal		•	•	•
Notificación de posibles delitos a las autoridades		•	•	•
Sistema interno de reclamaciones			•	•
Resolución extrajudicial de litigios			•	•
Colaboración con alertadores fiables			•	•
Medidas contra uso indebido de notificaciones de contenido ilegal			•	•
Informes de transparencia más estrictos			•	•
Prohibición de anuncios dirigidos a menores o datos sensibles			•	•
Transparencia en las recomendaciones para los usuarios			•	•
Publicidad transparente para los usuarios			•	•
Diseño de interfaces que permitan informarse y decidir libremente al usuario			•	•
Evaluación y reducción de riesgos				•
Mecanismo de respuesta a crisis				•
Auditorías independientes				•
Opción a sistemas de recomendación sin perfiles				•
Transparencia adicional sobre la publicidad				•
Acceso a datos para administraciones e investigadores				•
Códigos de conducta				•

Tabla 2: nuevas obligaciones bajo la Ley de Servicios Digitales.

Fuentes de información

(1) Ortutay, B. (2022) *Amnesty report finds Facebook amplified hate ahead of Rohingya massacre in Myanmar*, *PBS*. https://www.pbs.org/newshour/world/amnesty-report-finds-facebook-amplified-hate-ahead-of-rohingya-massacre-in-myanmar

(2) Watson, A. (2022) *Topic: Social Media News Consumption Worldwide*, *Statista*. https://www.statista.com/topics/9002/social-media-news-consumption-worldwide/

(3) Krass, P. (2022) *Transparency: The first step to fixing social media*, *MIT Initiative on the Digital Economy*. https://ide.mit.edu/insights/transparency-the-first-step-to-fixing-social-media/

(4) Jiang, R. et al. (2019). *Degenerate feedback loops in recommender systems.* In Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society (pp. 383–390).

(5) Meta. *Transparency reports*, *Transparency Center*. https://transparency.fb.com/reports/

(6) TikTok. *Reports*, *TikTok*. https://www.tiktok.com/transparency/en/reports/

(7) Cabral, A.R. (2023). *Elon Musk says Twitter will open source 'literally everything' as parts of code now public, The National News*. https://www.thenationalnews.com/business/technology/2023/04/01/elon-musk-says-twitter-will-open-source-literally-everything-as-parts-of-code-now-public/#:~:text=Alvin%20R%20Cabral%20Apr%2001%2C

(8) UE. (2023). *The Digital Services Act (DSA)*. https://www.eu-digital-services-act.com

(9) Gobierno de España. (2021). *Carta de Derechos Digitales*. https://www.lamoncloa.gob.es/presidente/actividades/Documents/2021/140721-Carta_Derechos_Digitales_RedEs.pdf

(10) GPAI. (2021). *Responsible AI for social media governance: A proposed collaborative method for studying the effects of social media recommender systems on users. Global Partnership on Artificial Intelligence report.*

(11) Boxell, L., et al. (2017). *Greater Internet use is not associated with faster growth in political polarization among US demographic groups*. Proceedings of the National Academy of Sciences, 114(40), 10612–10617.

(12) Alphabet. *Transparency reports.* https://transparencyreport.google.com/?hl=en_GB

(13) Twitter (2023). *Twitter's Recommendation Algorithm.* https://blog.twitter.com/engineering/en_us/topics/open-source/2023/twitter-recommendation-algorithm

(14) GPAI. (2022). *Transparency Mechanisms for Social Media Recommender Algorithms: From Proposals to Action*. https://gpai.ai/projects/responsible-ai/transparency-mechanisms-for-social-media-recommender-algorithms.pdf